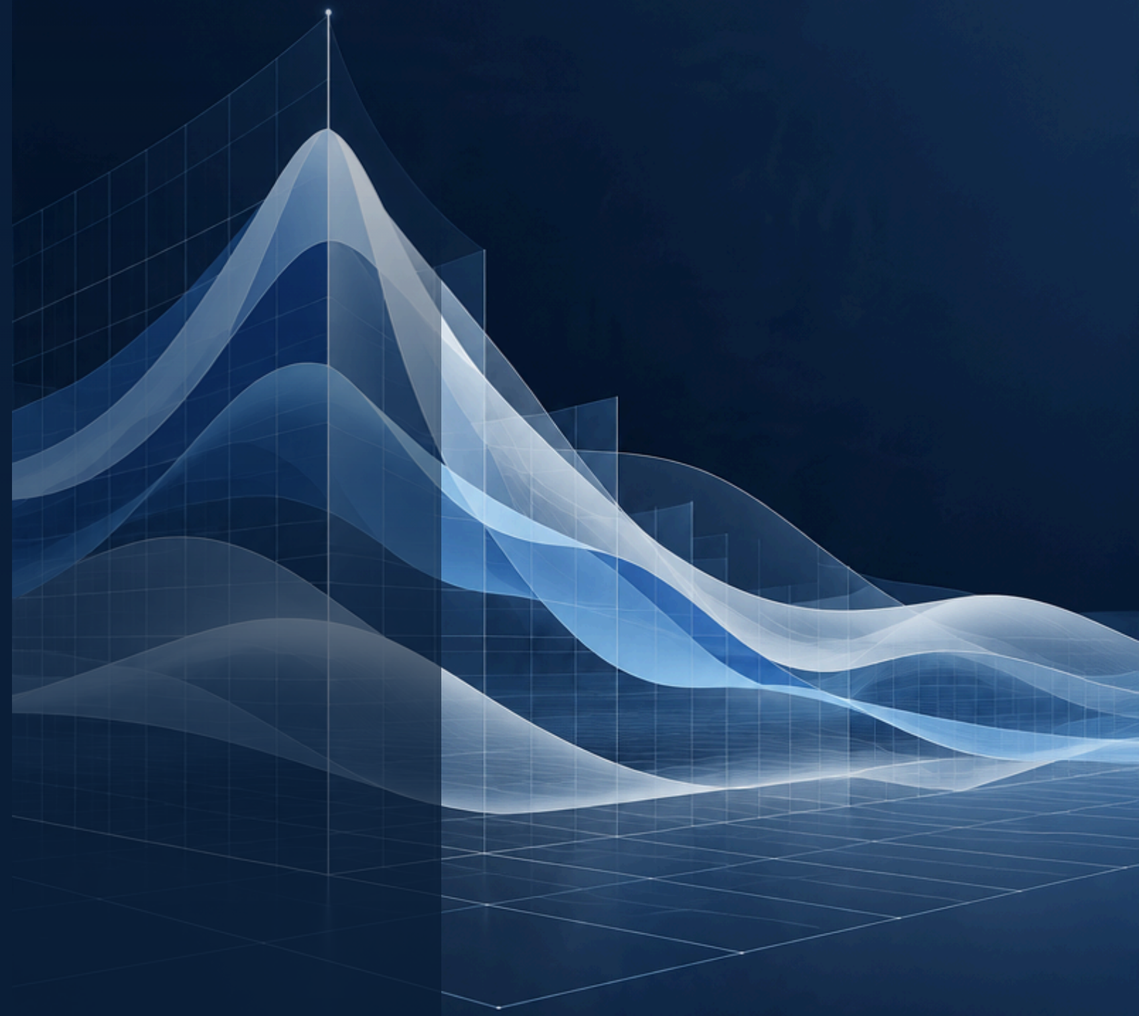
PILOTO ACADÊMICO

Estoque de segurança

Variabilidade do planejamento de produção + Machine Learning



Virgínia Pasini • Introdução à Ciência de Dados • UERJ

Proposta acadêmica

Um piloto demonstrativo — não uma política pronta para produção.

Pergunta

Como a variabilidade do plano afeta o estoque de segurança?

Método

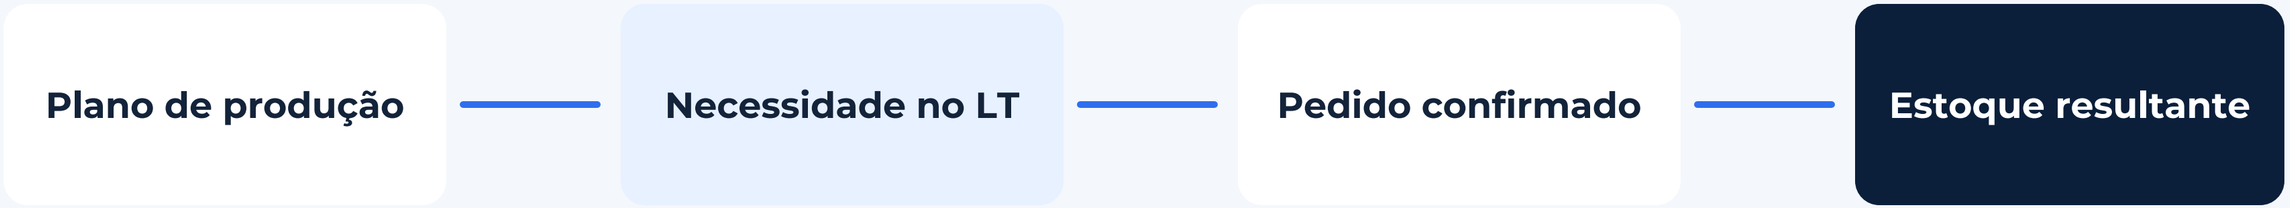
Base sintética, engenharia de atributos e validação temporal.

Entrega

Notebook reproduzível, métricas e limites explicitados.

Origem empresarial

A tensão nasce entre um plano que muda e um pedido que pode não mudar.



Hipótese central: picos dentro do lead time podem gerar exposição adicional — condicionada às regras de ajuste do pedido.

Base de demonstração

Cenário sintético MAQ-001 • 2025–2026 • corte: set/2026

21 **Meses consolidados**	**10** **Revisões por mês**	**240** **Registros de revisões**
13 Componentes (PNs)	**3** Fornecedores fictícios	**5** Meses de lead time

Base bruta: 24 meses / 240 revisões • 2025: 12 meses; 2026: 9 consolidados

Indicadores da metodologia

Quatro lentes complementares sobre estabilidade e risco operacional.

Pico no LT

máx(plano)

pressão máxima

Amplitude

máx − mín

oscilação interna

Variação final

Final − Plano LT

só meses fechados
variação de demanda

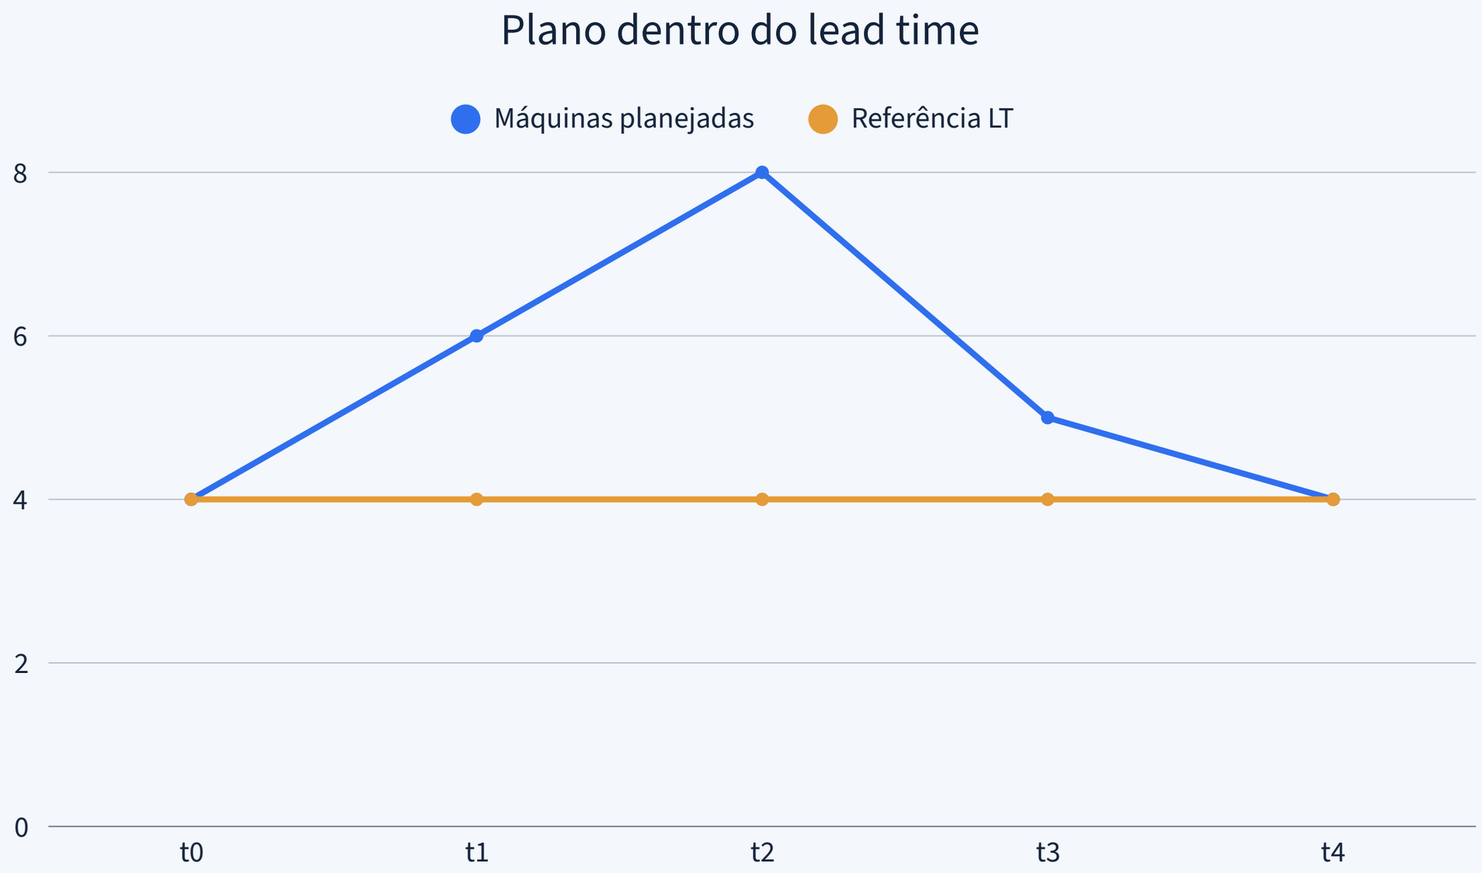
Erro preditivo

MAE + RMSE

qualidade do modelo

O pico também importa

A janela termina onde começou — mas o caminho até lá não foi neutro.



Pico +4

Amplitude 4

Variação final 0

O pico pode induzir pedido adicional fora do LT. Excesso só ocorre se o pedido confirmado não puder ser ajustado.

Estoque de segurança: abordagem empírica

21 meses sintéticos consolidados • ES=1: 90,5% • ES=2: 100% de cobertura histórica

Aumento final = máx(0, Plano final − Plano LT)

critério do ES

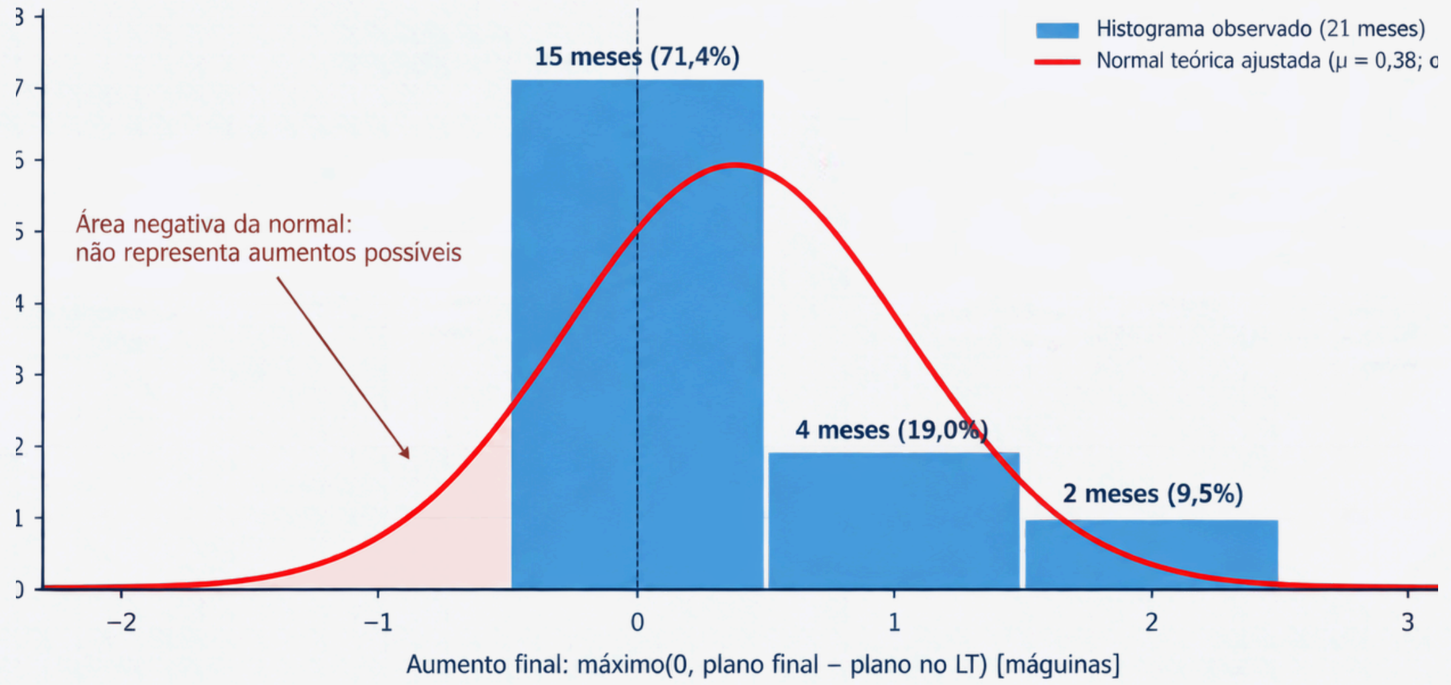
aumento final consolidado
cobertura histórica empírica
sem pressupor normalidade

análise separada

picos intermediários
pedidos extras fora do LT
possível impacto operacional

Por que utilizar a distribuição empírica?

Aumentos finais observados (21 meses) × curva normal teórica ilustrativa



71,4% dos meses apresentam aumento final zero. Distribuição discreta e assimétrica.
Por isso, o ES é dimensionado pela cobertura histórica empírica, não pela curva normal.

Base sintética: 21 meses consolidados (jan/2025–set/2026). Curva normal apenas ilustrativa.

Resultado empírico do estoque de segurança

Saída real do notebook • ES = 2 máquinas equivalentes • 21 meses elegíveis
Base sintética • Meta ilustrativa de cobertura histórica: 95%

```
=== RESUMO EXECUTIVO | PILOTO SINTÉTICO MAQ-001 ===
Base total: 24 meses | elegíveis para ES: 21 | não consolidados: 3
Observações disponíveis para ML após defasagens: 15 | meses de teste: 3
ES demonstrativo: 2 máquinas equivalentes
Cobertura histórica FINAL: 100.0% | meta ilustrativa: 95%
Cobertura histórica do PICO pós-LT no mesmo ES: 90.5%

Distribuição dos aumentos finais após LT:
```

	Aumento_final_maquinas	Meses	Frequencia_%
0	0.0	15	71.43
1	1.0	4	19.05
2	2.0	2	9.52

ES por PN (considerando consumo específico):

	PN sintético	Qtd por máquina	ES_simulado_un	Cobertura_historica_%
0	PN-0001	1	2	100.0
1	PN-0002	1	2	100.0
2	PN-0003	1	2	100.0
3	PN-0004	1	2	100.0
4	PN-0005	1	2	100.0

90,5% de cobertura dos picos

Picos intermediários pós-LT
Abaixo da meta ilustrativa de 95%
Risco exige avaliação específica

100% de cobertura final

Aumento final pós-LT
15 meses: zero • 4: +1 • 2: +2
21 meses cobertos no histórico

Por que regressão supervisionada?

Estimar o aumento final com informações disponíveis na decisão de compra (LT).



Baseline · Ridge · Random Forest | Sem informações futuras; modelo exploratório, complementar ao ES empírico.

Modelos e validação

15 meses elegíveis: 12 iniciais para treino e 3 posteriores para teste, sem embaralhamento.

Baseline

Simples e interpretável
Referência com histórico limitado

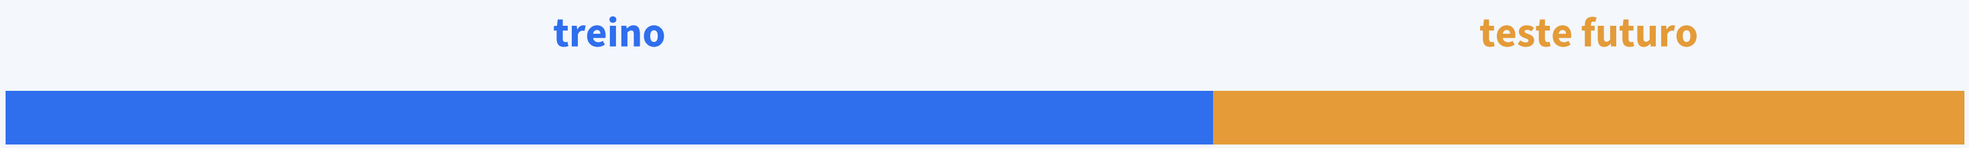
Ridge

Relações lineares
Regularização reduz instabilidade

Random Forest

Padrões não lineares
Validação cuidadosa

CRITÉRIOS
MAE + RMSE



RECOMENDAÇÃO DO MODELO
Indicação conforme o histórico disponível, a confiabilidade dos resultados e as limitações do cenário analisado.

Resultados experimentais

Comparação dos modelos em três meses de teste cronológico.



Principais resultados do teste

O Baseline apresentou o menor erro absoluto médio, enquanto o Ridge obteve o menor RMSE. Com apenas três meses de teste, os resultados são exploratórios e não permitem estabelecer superioridade consistente entre os modelos.

Demonstração no Google Colab

Execução real do piloto: comparação temporal dos modelos e previsões fora da amostra.

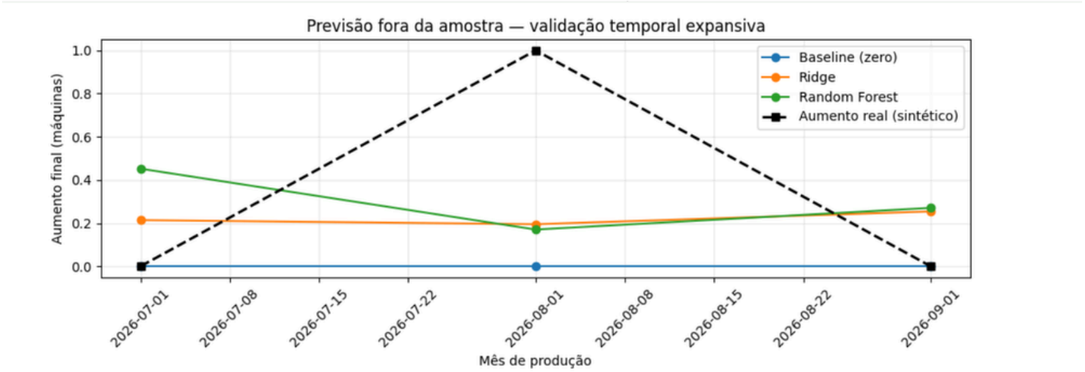
```
Meses utilizáveis após defasagens: 15 de 21
Comparação temporal — valores em máquinas equivalentes:
```

	Modelo	Meses_teste	MAE	RMSE	Faltas_simuladas_un	Excesso_simulado_un
0	Baseline (zero)	3	0.333	0.577	1.0	0.0
1	Ridge	3	0.424	0.503	0.0	2.0
2	Random Forest	3	0.518	0.567	0.0	2.0

```
ATENÇÃO: arredondar a previsão para cima é uma política ilustrativa de cobertura, não um ES estatisticamente validado.
Hiperparâmetros escolhidos em cada mês (somente com dados anteriores):
```

	Mes_teste	Modelo	Parametros	MAE_validacao
0	2026-07-01	Ridge	{'alpha': 0.1}	0.245266
1	2026-07-01	Random Forest	{'max_depth': 2, 'min_samples_leaf': 3, 'n_est...	0.347291
2	2026-08-01	Ridge	{'alpha': 1.0}	0.282382
3	2026-08-01	Random Forest	{'max_depth': 2, 'min_samples_leaf': 3, 'n_est...	0.412728
4	2026-09-01	Ridge	{'alpha': 10.0}	0.533229
5	2026-09-01	Random Forest	{'max_depth': 2, 'min_samples_leaf': 3, 'n_est...	0.633347

```
Arquivo gerado: hiperparametros_ml_piloto.csv
```




```
Modelo com menor MAE neste teste: Baseline (zero)
Meses de teste: 3
Diagnóstico: os modelos treinados NÃO superaram o baseline em MAE.
Limitações: dados sintéticos; uma máquina; PNs dependentes; poucos meses de treino/teste; previsões sem intervalo de confiança calibrado.
Arquivos gerados: previsoes_ml_piloto.csv, metricas_ml_piloto.csv
```

Resultados do Google Colab • 3 meses de teste

Baseline: menor MAE; Ridge: menor RMSE. Dados sintéticos e teste reduzido: resultados exploratórios.

Medir o caminho, não apenas o saldo.

Limitações e próximos passos

No piloto sintético, ES = 2 cobriu 100% dos aumentos finais, mas apenas 90,5% dos picos pós-LT. A avaliação de ML utilizou só 3 meses de teste.

1 Validar ES e picos com dados reais

2 Ampliar a validação temporal de ML

3 Avaliar faltas, excessos e custos

Baseline: menor MAE • Ridge: menor RMSE • Evidências exploratórias, não política operacional validada.